Note book GGplot_3

Utilisation de GGplot_2

GGplot2 est une extension du tidyverse qui permet de générer des graphiques avec une syntaxe cohérente et puissante. Elle nécessite l apprentissage d un mini-langage supplémentaire, mais permet la construction de graphiques complexes de maniere éfficace.

Une des particularités de GGplot2 est que l extension part du principe que les données relatives à un graphique sont stockés dans un tableau de données (data frame, tibble ou autre).

Les prérequis :
Il faut tout d abord avoir un data frame du type

```
library(ggplot2)
head(mpg)
```

```
## # A tibble: 6 x 11
##   manufacturer model displ  year   cyl trans      drv     cty   hwy fl    class
##   <chr>        <chr> <dbl> <int> <int> <chr>      <chr> <int> <int> <chr> <chr>
## 1 audi         a4      1.8  1999     4 auto(l5)   f        18    29 p     compa~
## 2 audi         a4      1.8  1999     4 manual(m5) f        21    29 p     compa~
## 3 audi         a4      2    2008     4 manual(m6) f        20    31 p     compa~
## 4 audi         a4      2    2008     4 auto(av)   f        21    30 p     compa~
## 5 audi         a4      2.8  1999     6 auto(l5)   f        16    26 p     compa~
## 6 audi         a4      2.8  1999     6 manual(m5) f        18    26 p     compa~
```

Une fois le tableau initialisé, il est temps de jouer avec les données. La manipulation passe par deux axes clés :
- la definition des variables sur leur axe respéctifs
- le type de graphique à utliser.

Il existe une multitude de graphiques qui ont chacun une fonction bien précise.

Le nuage de point

Definition: en statistiques, un nuage de points est une représentation de données dépendant de plusieurs variables. Il permet de mettre en évidence le degré de corrélation entre au moins deux variables liées. Les différentes observations des nuages de points permettent de déterminer : Des tendances Des dépendances. Utilisable avec la fonction : geom_point (qui permet de modifier : taille, couleur et forme des points).

Une fois l intialisation terminée, il faut utliser la fonction suivante :

```
ggplot(mtcars, aes(x=wt, y=mpg))+ geom_point()
```

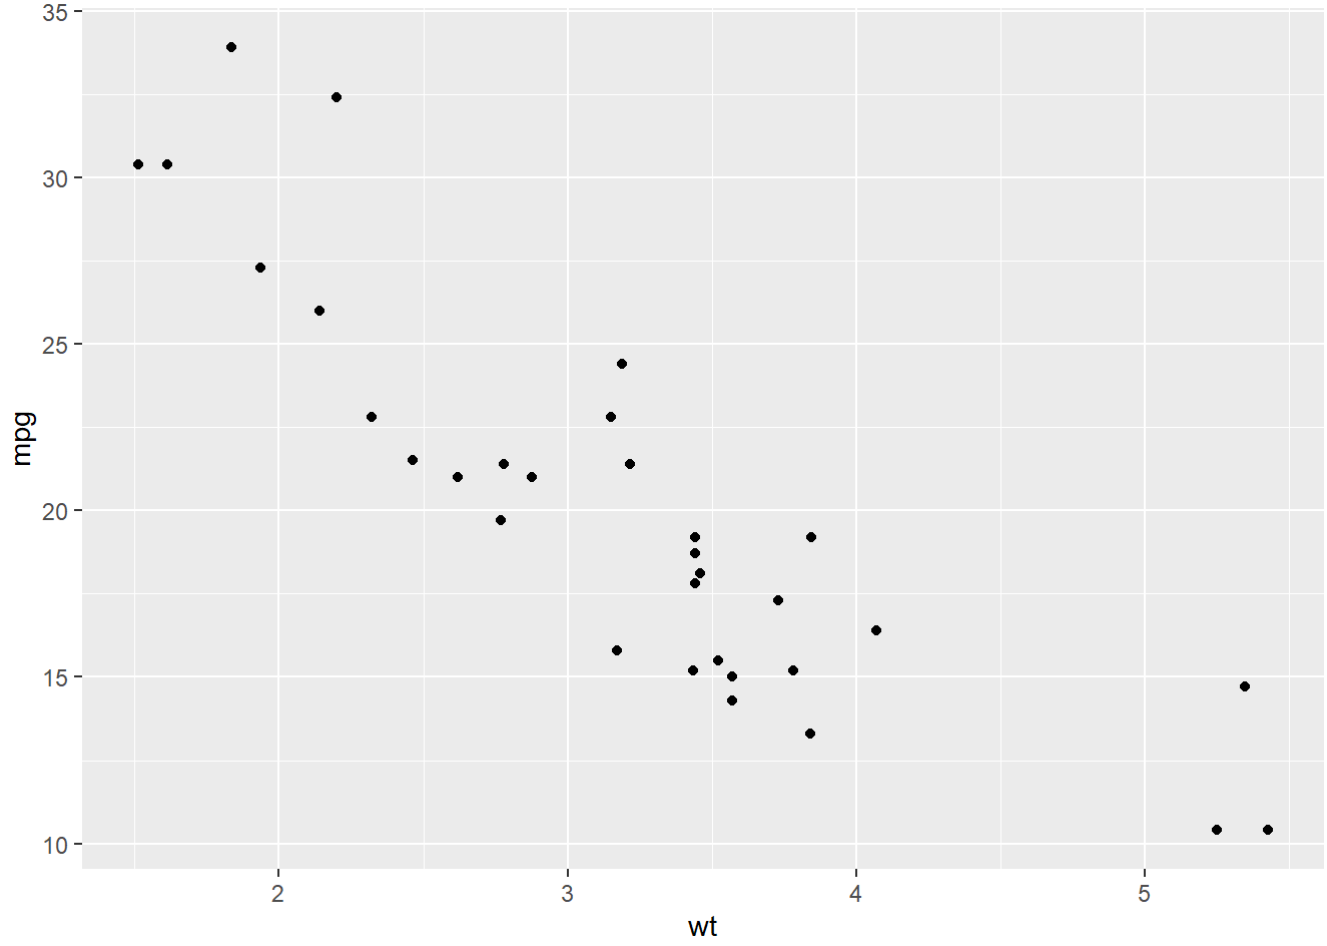


```
#(definition du DataFrame, definition des axes : aes (x = , y = )+ geom_point()
```

Pour la question des points, tout est dans la definition du “geom_point”, personalisable à l’infini

```
ggplot(mpg) +
  geom_point(aes(x = cyl, y = displ),
             color = "darkgreen", size = 3, alpha = 0.3)
```

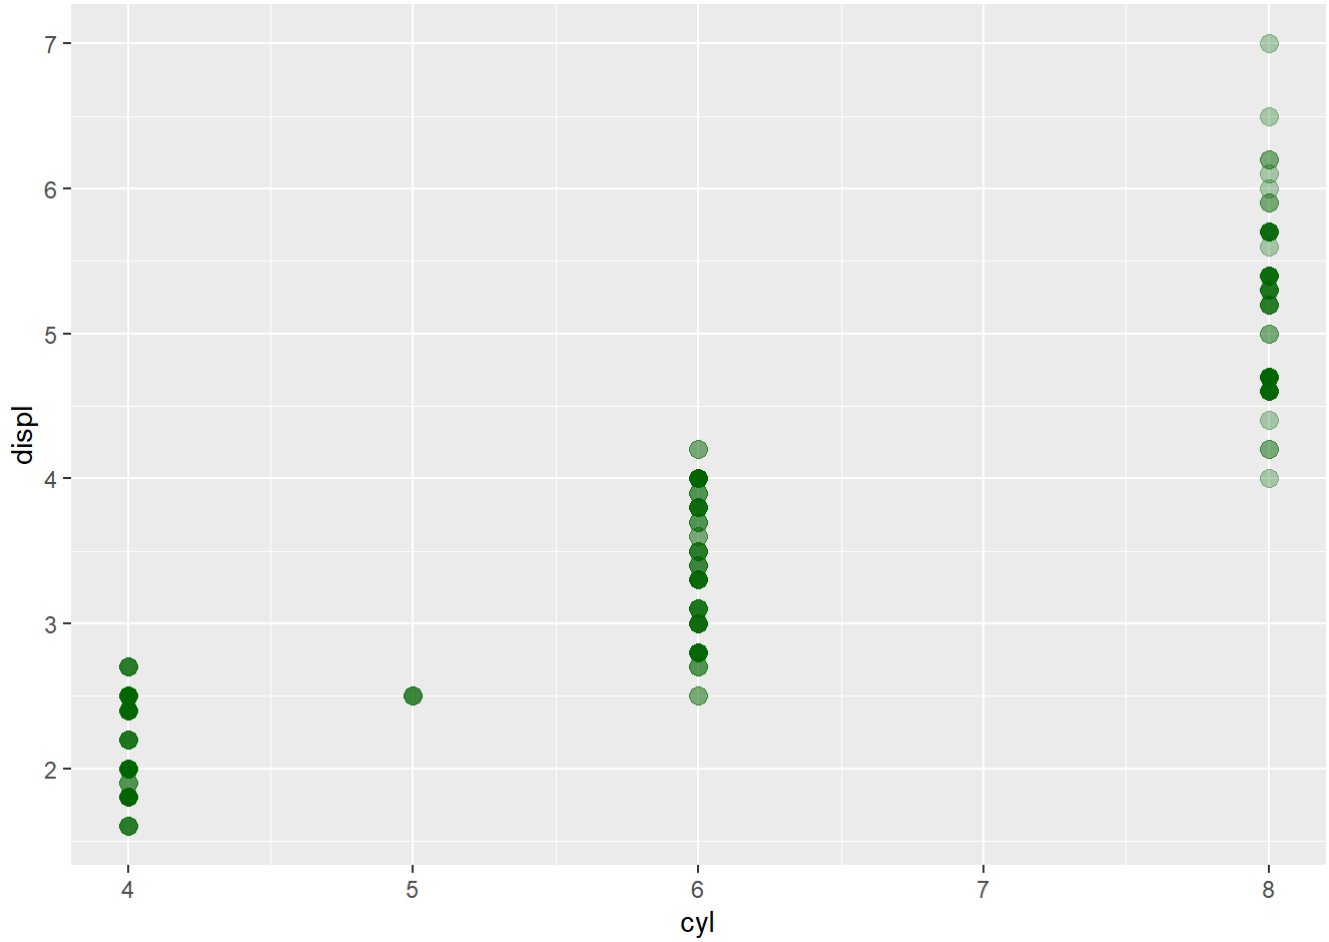

Les Histogrammes:

Definition : Représentation graphique des fréquences ou effectifs relatifs à un caractere quantitatif continu à l'aide d'une série de rectangles dont la base constitue un intervalle de variation des valeurs du caractere et la surface l effectif correspondant. Pour cela, il faut utiliser la commande : geom_histogram qui se configure de la manière suivante :

```
ggplot(mpg) + geom_histogram(aes(x = cyl))
```

```
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
```

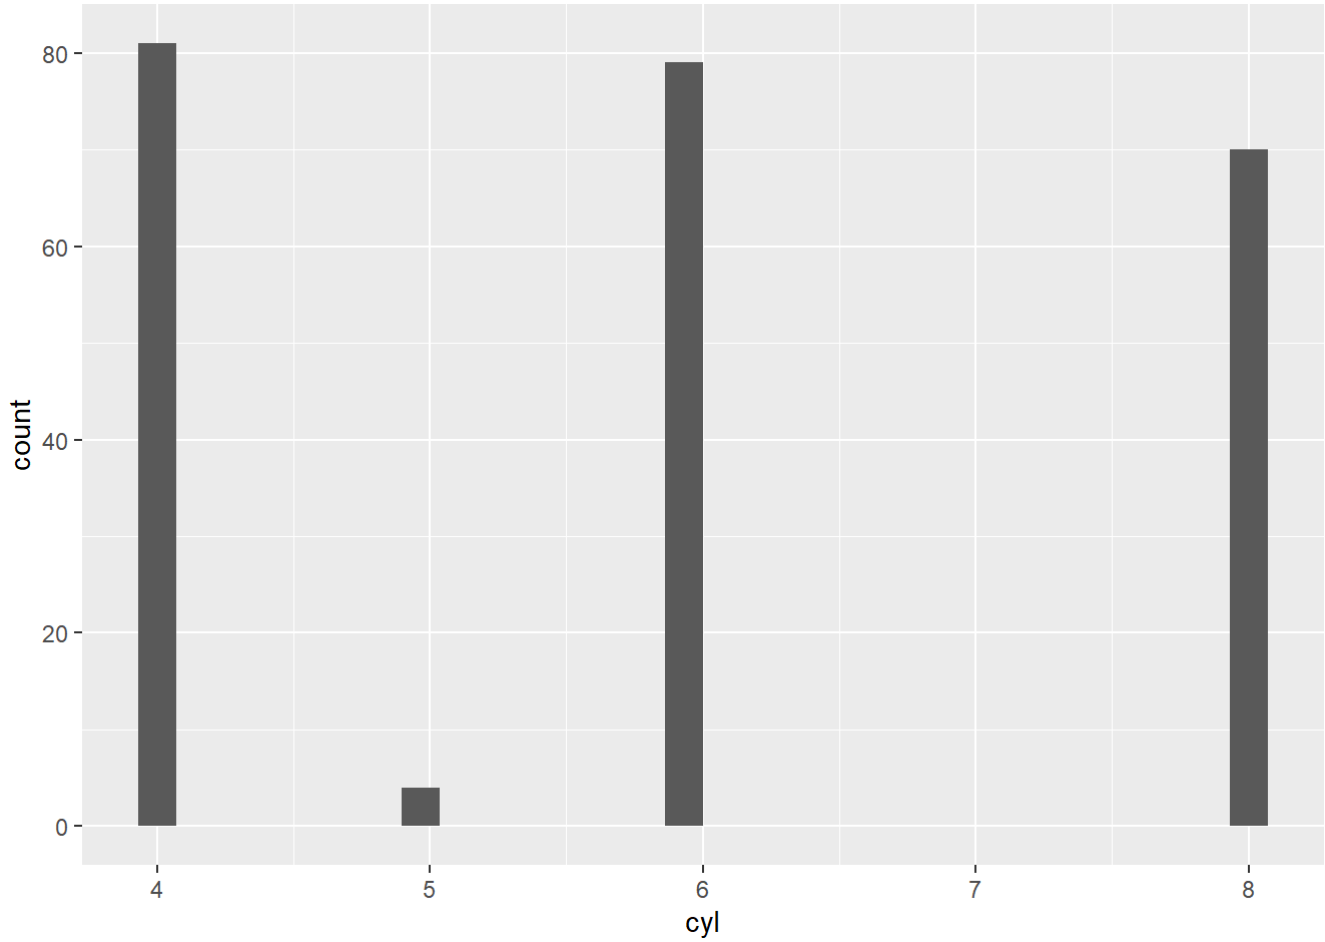

Definir X permet d'afficher la donnée que l'on souhaite representer.

LES BOITES A MOUSTACHE :

Definition : Dans les représentations graphiques de données statistiques, la boite à moustaches est un moyen rapide de figurer le profil essentiel d une série statistique quantitative. Elle a été inventée en 1977 par John Tukey, mais peut faire l objet de certains aménagements selon les utilisateurs.

utilisable avec la commande : "geom_boxplot" :

```
ggplot(mpg) + geom_boxplot(aes(x = cty , y = hwy),fill = "wheat", color = "blue")
```

```
## Warning: Continuous x aesthetic -- did you forget aes(group=...)?
```

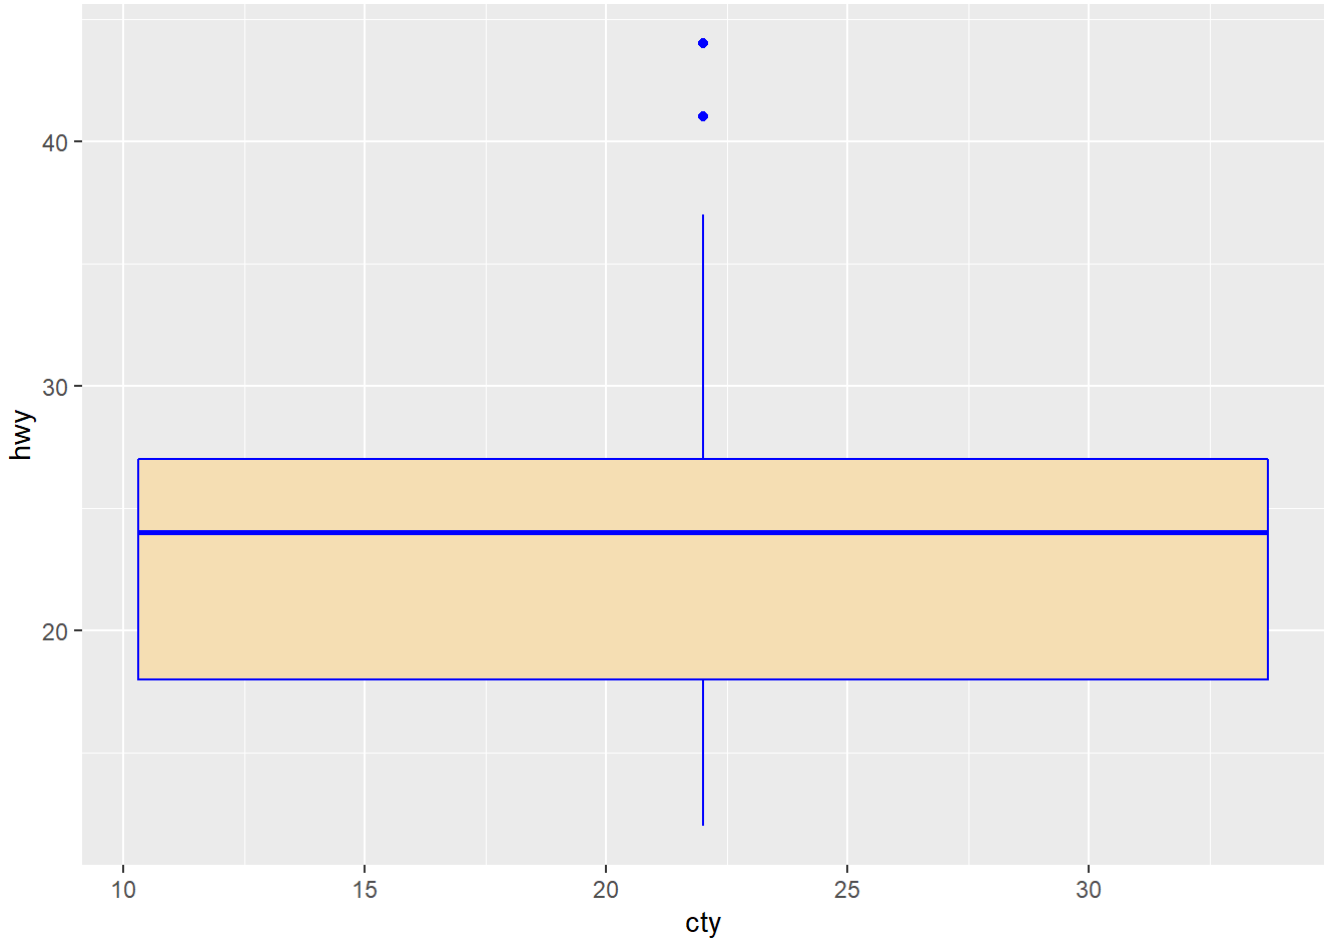

exemple toujours avec le tableau ci dessus Personnalisable avec les commandes :

Toujours avec les boites à moustaches, la commande “varwidth” permet de varier la longueure des boites en fonctions des effectifs de la catégorie. Pour l’appliquer, on fait :

```
ggplot(mpg) + geom_boxplot(aes(x = cyl, y = drv), varwidth = TRUE)
```

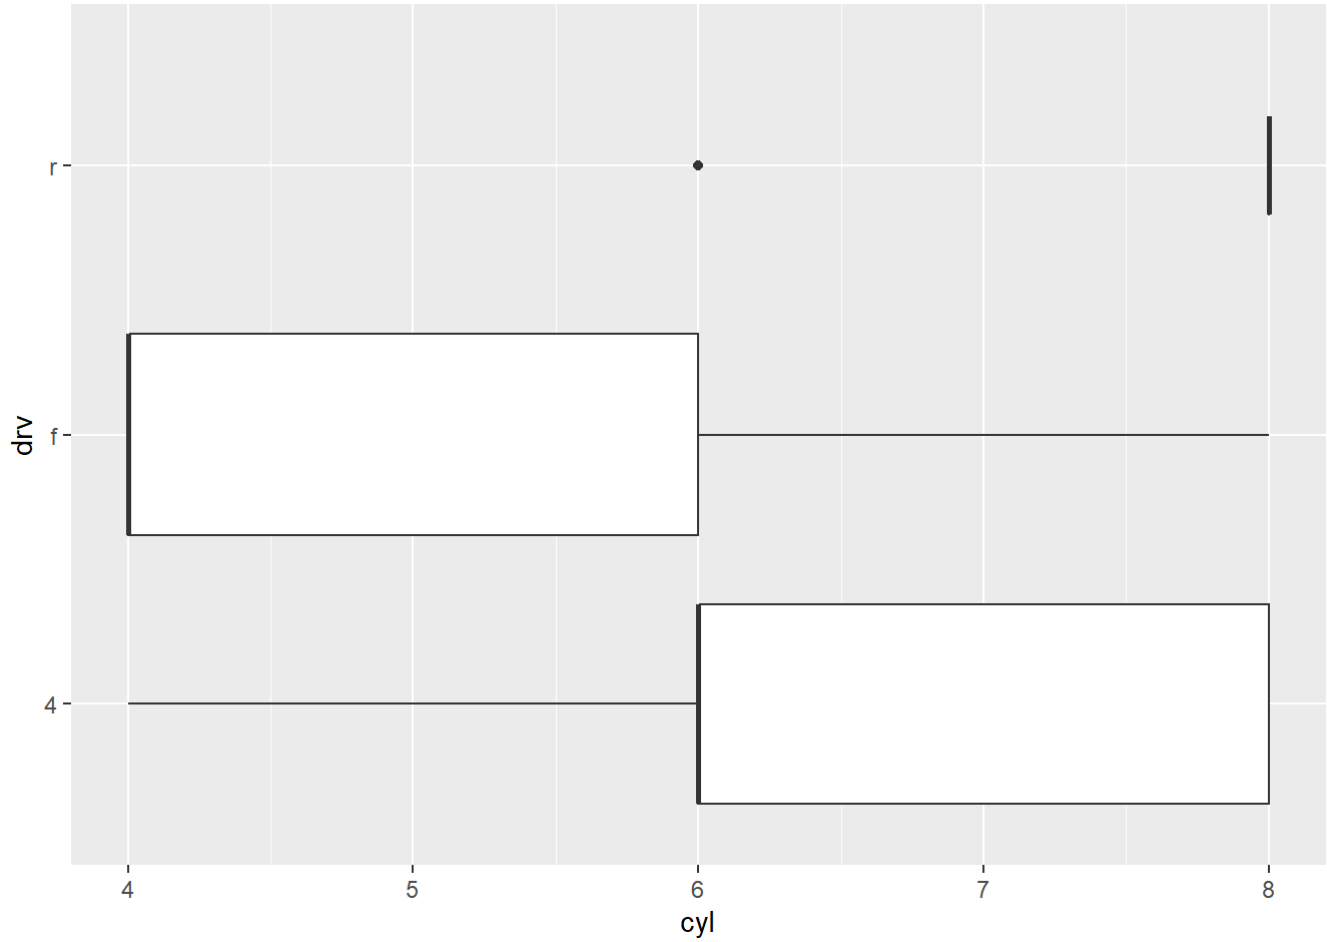

Pour cela, il faut utiliser la commande : geom_histogram qui se configure de la manière suivante

geom_histogram(aes(x = mpg))

Definir X permet d afficher la donnée que l on souhaite representer.

Geom_violin :

geom_violin est tres semblable à geom_boxplot, mais utilise des graphes en violon à la place des boites à moustache. Les graphes en violon peuvent donner une lecture plus fine des différences de distribution selon les classes.

```
ggplot(mpg) + geom_violin(aes(x = cyl, y = displ))
```

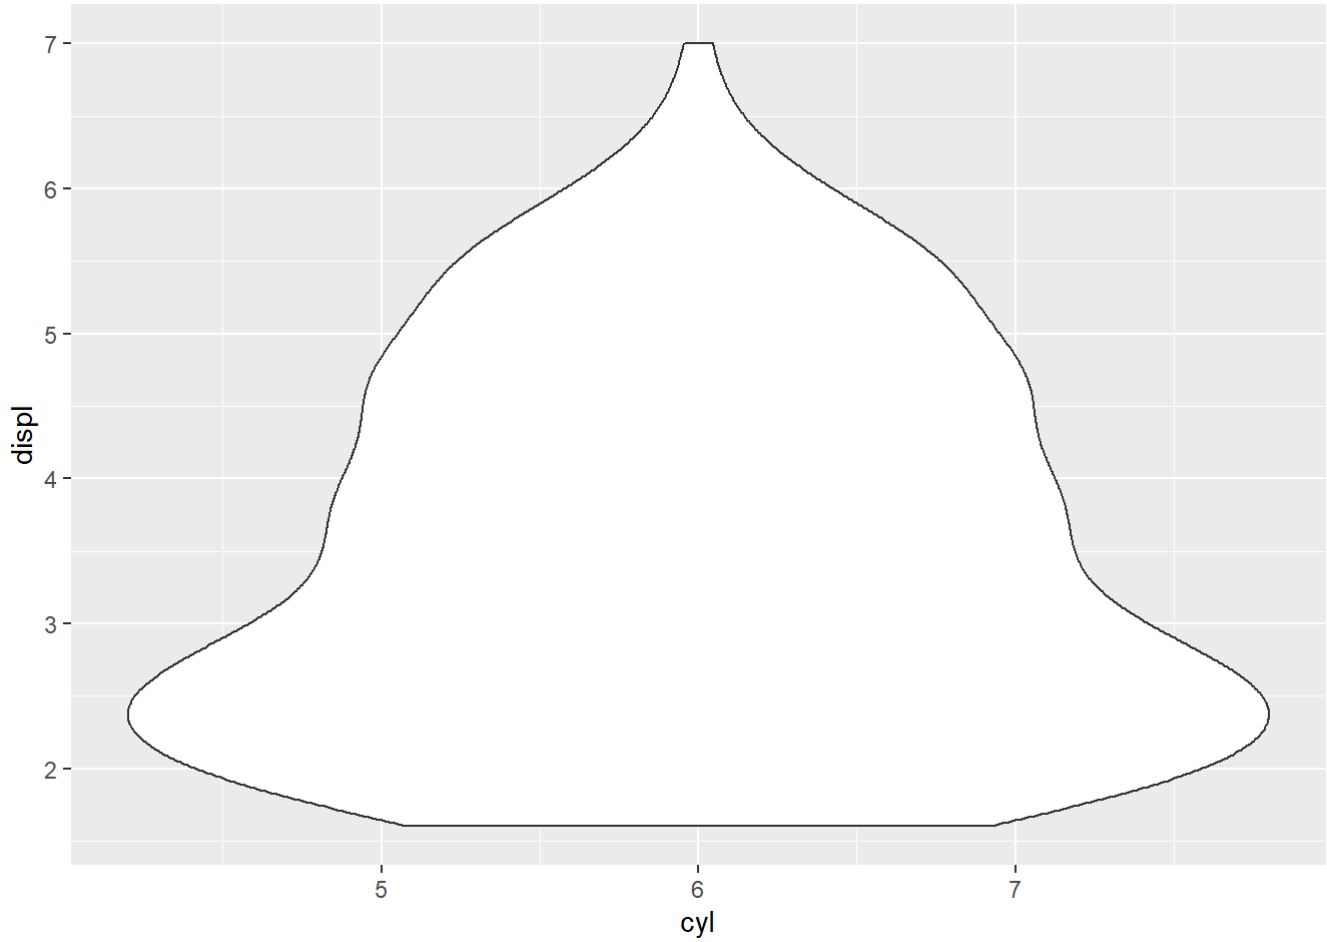

Utlisation de GGplot2 sur des dossiers CSV : l'exemple de notre base de donnée Covid

Les prérequis :

library(lubridate)#Utilisation de la fonction {dmy} pour changer le format de date de notre fichier. library(ggplot2) #Utilisation des fonctions pour réaliser des graphiques. library(dplyr)#Utilisation de la fonction {filter} pour pour filter certainnes donneés clés que nous souhaitons afficher.

Etape 1 : lire le fichier CSV

on demande au programme de lire le fichier CSV qui contient nos données a plat on renomme ce dossier data_covid read.table("donneeaplatcovid2.csv" [nom du fichier],header=TRUE [titre des colonnes],sep=';' [permet de determiner quel est le type de separateur],dec='.' [decimal] data_covid<- read.table("donneeaplatcovid2.csv",header=TRUE,sep=';',dec='.') on a constater que la colonne "JOUR" avait un nom différent, pour voir ce nom on effectue la commande suivante : names(data_covid[1] puis la fonction ci dessous)

colnames(data_covid)[colnames(data_covid) == names(data_covid[1])] <- 'JOUR'

head(data_covid) str(data_covid)

#permet de connaitre le nom de la premiere colonne (names(data_covid[1]) #permet de changer le nom de la premiere colonne (cf ligne 15)

on a le probleme du format de date, pour cela on execute la commande ci dessous pour changer le format : (data_covid"JOUR <- dmy(data_covid"JOUR)#transformation du format de la colonne JOUR en date OU FONCTION dplyr::glimpse(data_covid)

ggplot(data_covid, aes(x=JOUR, y=REA)) + geom_line()

Phase de filtre : losque l'on plot les données covid, on se retrouver avec toutes les données de tous les departements ici on cherche seulement les donées du 95 covid_95 <- dplyr::filter(data_covid,DEP==95)#permet de selectionner le departement

pour les deux commandes suivantes, on crée une variable p et q qui montrent des donneés differentes toujours en fonction des jours p <- ggplot(covid_95, aes(x=JOUR, y=HOSP)) + geom_line(colour = 'blue') p

q <- ggplot(covid_95, aes(x=JOUR, y=REA)) + geom_line(colour = 'green') q

ici il s'agit de la commande initiale ou l'on voit tous les departement
ggplot(data_covid, aes(x=JOUR, y=HOSP)) + geom_point()#s'affiche normalement

##Utilisation des graphiques avec ESQUISSE

Cet addin vous permet d'explorer de manière interactive vos données en les visualisant avec le package ggplot2 . Il vous permet de dessiner des graphiques à barres, des courbes, des nuages de points, des histogrammes, des boîtes à moustaches et des objets sf , puis d'exporter le graphique ou de récupérer le code pour reproduire le graphique.

Pour acceder à cette fonction il faut aller dans Rstudio :

ADDINS -> GGPLOT BULDER

les facettes :

```
library(ggplot2)
dataframe <- data.frame(mpg) #definition du DataFrame

ggplot(dataframe) +
 aes(x = displ, y = cyl) +
 geom_point(size = 1L, colour = "#0c4c8a") +
 theme_minimal() +
 facet_wrap(vars(cty))
```

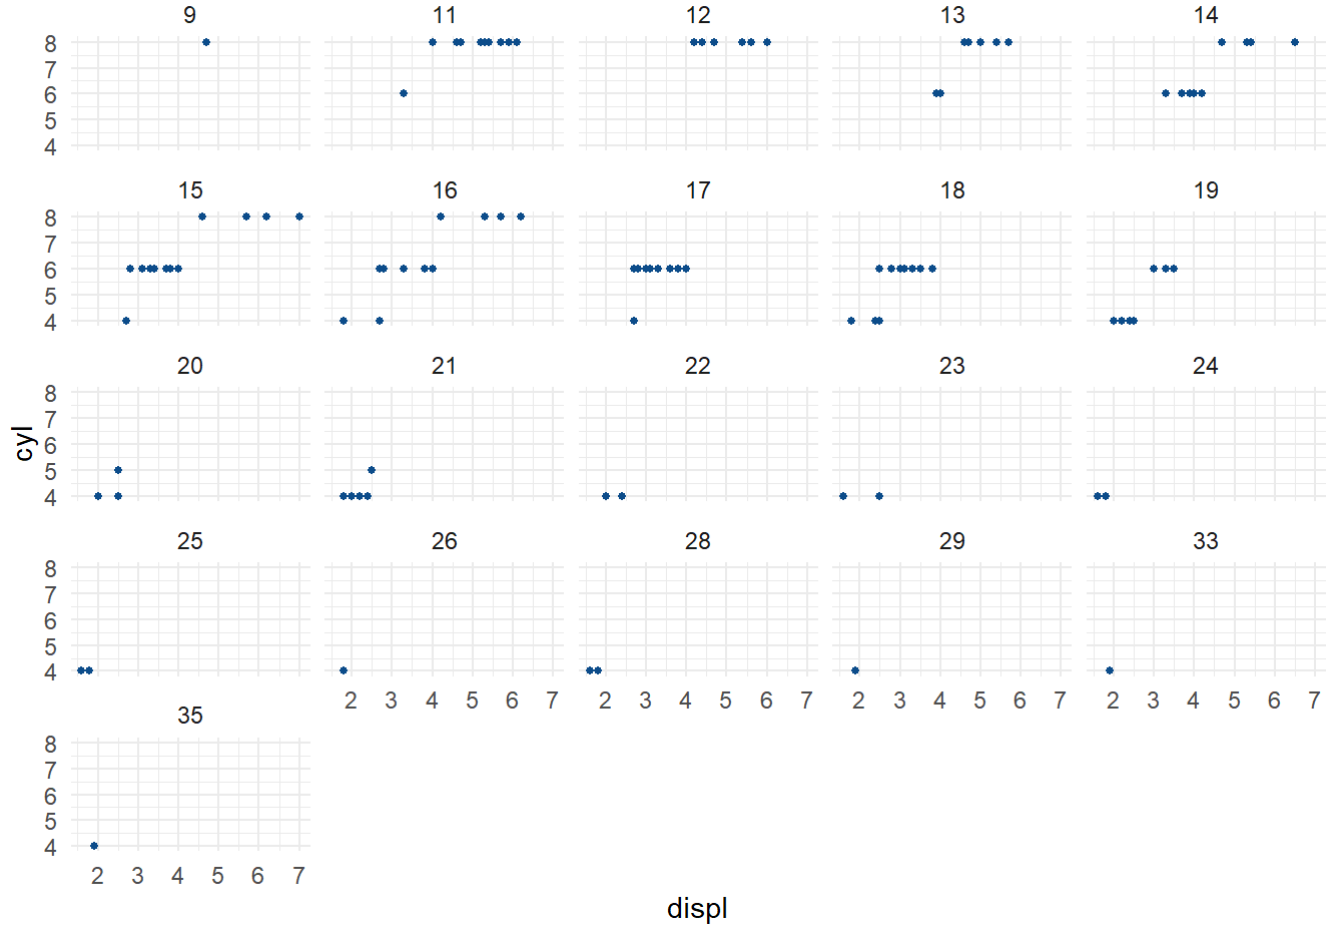

Grâce à cette fonctionalité, il est enfantin et didactique de faire des graphiques en tout genre, il suffit juste d'indiquer à la machine quelle est le DataFrame à utiliser et les paramètres à définir.

Utilisation des facettes

Nous allons utliser la librairie (mpg) afin d'illustrer les différents exemples

Cette fonction est équivalente à ggplot2::facet_grid()en ce qu'elle permet de construire une grille de petits multiples où les lignes et les colonnes correspondent à une valeur de données spécifique.

Bien que cela ggplot2::facet_grid() puisse être utilisé, cela entraînerait des résultats inattendus car il n'est pas possible de spécifier si vous faites référence à un nœud ou à un attribut d'arête. De plus ggplot2::facet_grid(), dessine les bords dans les panneaux même si le panneau ne contient pas les deux nœuds terminaux.

Facet_graphprend en charge tous ces problèmes, vous permettant de définir le type de données auquel les lignes et les colonnes font référence, ainsi que de filtrer les bords en fonction des nœuds de chaque panneau (même lorsque les nœuds ne sont pas dessinés).

```
#install.packages("igraph")

ggplot(mpg) +
  aes(x = displ, y = cty) +
  geom_line(size = 1L, colour = "#0c4c8a") +
  theme_grey() +
  facet_wrap(vars(year))
```

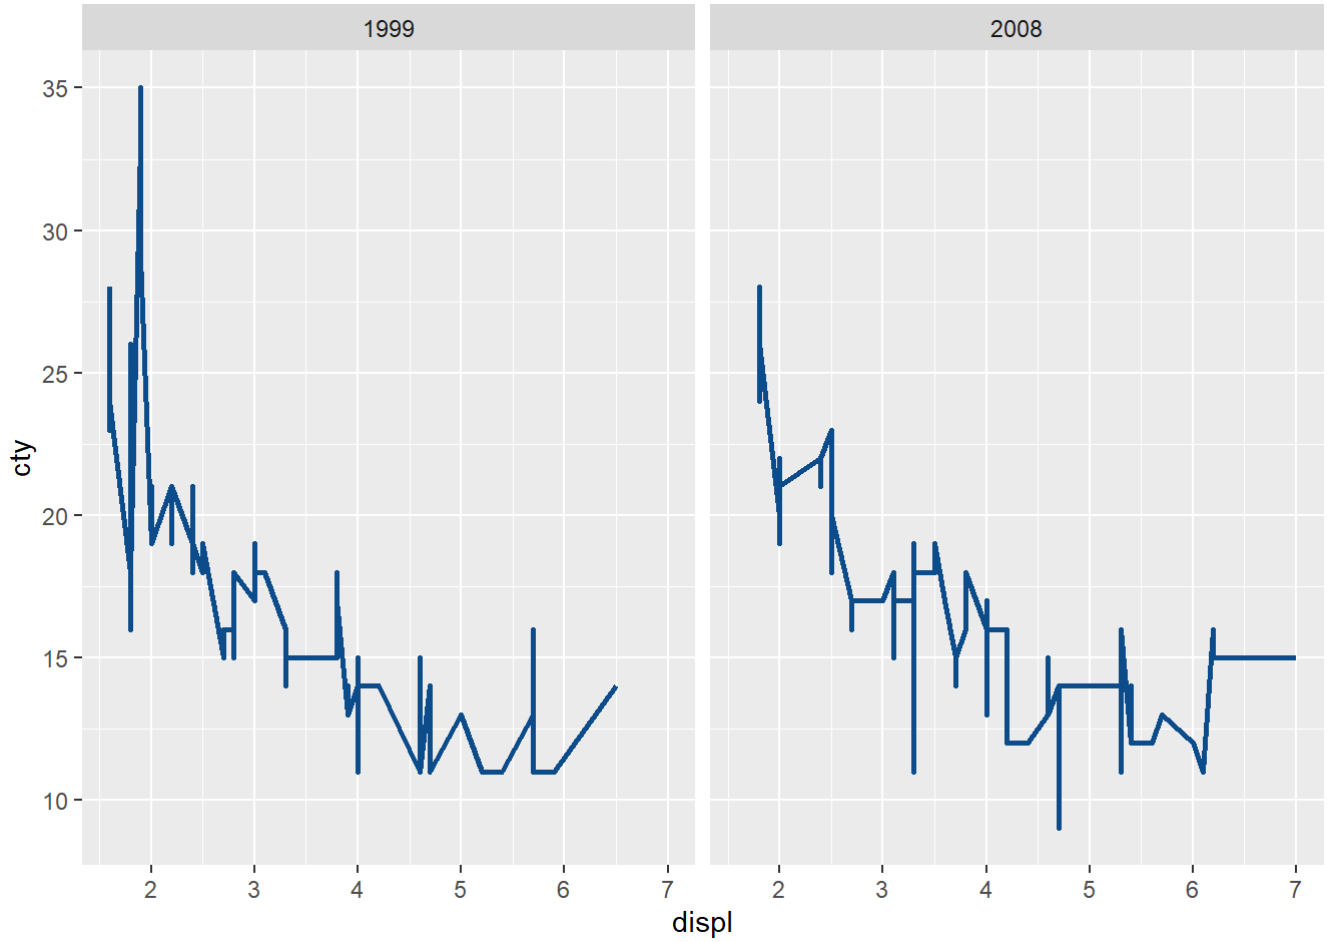

Le fait d'utiliser la fonction igraph permet notamment de pouvoir afficher plusieurs graphiques pour notamment comparer l'allure générale des différentes variables.

Utilisation des correlations

En probabilités et en statistique, la corrélation entre plusieurs variables aléatoires ou statistiques est une notion de liaison qui contredit leur indépendance.

L'objectif va donc consister à mesurer la puissance du lien qu'il y a entre deux (ou plusieurs) variables. Or ce lien peut être plus ou moins complexe. On pense tout d'abord à un lien de type linéaire … et par extension on va vite se tourner vers la régression linéaire pour trouver ce lien.

Malheureusement toutes les relations de dépendances ne sont pas forcément linéaire, et donc il va falloir pousser plus loin les régressions (polynomiale, etc.). Nous allons donc nous tourner vers la corrélation de Spearman (rho) qui évalue la relation monotone entre deux variables. Dans une relation monotone, les variables ont tendance à changer ensemble, mais pas nécessairement à un taux régulier.

Pour calculer la correlation entre deux variables on peut utliser la fonction : "cor", qui fonctionne de la manière suivante :

```
cor(mpg$hwy,mpg$cty)
```

```
## [1] 0.9559159
```

Avec cela on obtient la correlation entre les variables "hwy" et "cty". Par conséquent, nous allons utiliser un data frame pour voir toutes les corrélations entre les variables numériques.
Ainsi, nous avons la matrice de correlation :

```
df <- data.frame(mpg$displ,mpg$cyl,mpg$cty,mpg$hwy)#creation d'un DataFrame avec les variable
s numériques
mc <- cor(df)#utlisation de ma fonction correlation pour obtenir la matrice de correlation
mm <- as.matrix(mc* mc) # La matrice au carée permet de n'avour que des valeurs positives.
print(mm)
```

```
##           mpg.displ   mpg.cyl   mpg.cty   mpg.hwy
## mpg.displ 1.0000000 0.8653225 0.6376405 0.5867867
## mpg.cyl   0.8653225 1.0000000 0.6492676 0.5805104
## mpg.cty   0.6376405 0.6492676 1.0000000 0.9137752
## mpg.hwy   0.5867867 0.5805104 0.9137752 1.0000000
```

Ainsi, nous avons la matrice de correlation, pour faciliter les interpretation nous allons sortir une matrice nous permettant de retenir toutes les coorelations supérieur 0.6 on fait :

```
mm[mm>0.7] <- 1
mm[mm<=0.7] <- 0
print(mm)
```

```
##           mpg.displ mpg.cyl mpg.cty mpg.hwy
## mpg.displ         1       1       0       0
## mpg.cyl           1       1       0       0
## mpg.cty           0       0       1       1
## mpg.hwy           0       0       1       1
```

Une fois la matrice réalisée, nous allons utiliser la fonction “graph_from_adjacency_matrix” qui nous pemettera de voir en un coup d’oeil les différentes corrélations.

Pour cela il faut utiliser la librairie igraph. cela nous permet de pouvoir mettre de maniere graphique les relation entre les différentes variables

```
library(igraph)
```

```
##
## Attaching package: 'igraph'
```

```
## The following objects are masked from 'package:stats':
##
##     decompose, spectrum
```

```
## The following object is masked from 'package:base':
##
##     union
```

```
network <- graph_from_adjacency_matrix(mm)
plot(network)
```

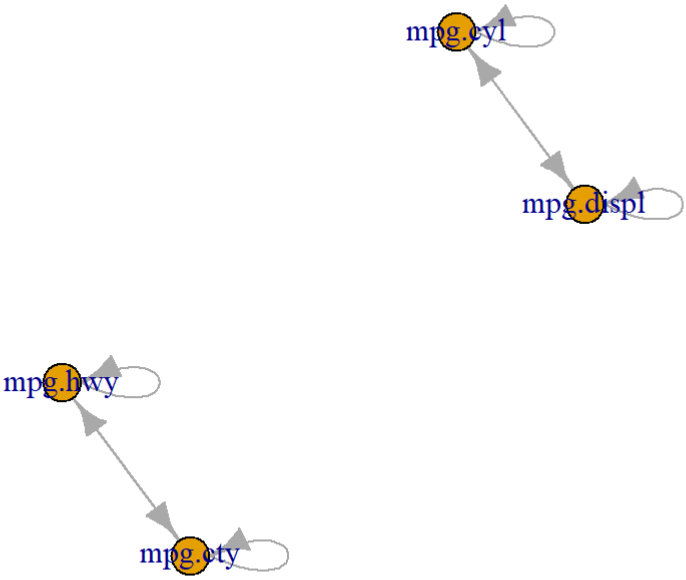

Pour plus d’information :

https://juba.github.io/tidyverse/08-ggplot2.html#ressources-1 (https://juba.github.io/tidyverse/08-ggplot2.html#ressources-1)